

FinLens · Propuesta de MVP

Research financiero multimodal con cifras verificadas

Taller B5-T4 · Máster en IA y computación cuantitativa aplicada a mercados financieros (Instituto BME)
Equipo: Pietro Rodrigues, Alonso y Raúl Rodríguez · 7 de octubre de 2026 · Startup ficticia: el modelo de negocio es un ejercicio.

Demo desplegada

https://108-128-114-211.sslip.io

Contraseña

solicítala al equipo

Despliegue

AWS · región eu-west-1 · EC2 t3.micro + Caddy (HTTPS) · imagen en ECR · secretos en Secrets Manager · CI/CD con GitHub Actions

Repositorio

https://github.com/pietro/Master-MIAX-Tarea-Bloque5-Multimodales

Resumen

0,060 USD

coste por análisis completo
(6 ejecuciones medidas, 99 % coste real)

31,4 s

análisis completo · nota en pantalla en 21,9 s

6 + 3

modelos de IA especializados + fuentes de datos

≈ 83 %

margen bruto del plan Pro sobre el coste de IA

- **Problema:** el analista cruza a mano informe, gráfico, audio y mercado, y la IA genérica inventa cifras.
- **Solución:** una consulta devuelve una nota donde **cada cifra cita su fuente y la verifica el código**, no el LLM.
- **Viabilidad:** el coste y la latencia están medidos con APIs reales y cumplen el objetivo del MVP.
- **Compliance:** la herramienta informa y no asesora; hay un guardrail determinista y un aviso legal en cada salida.

1. Definición del producto

1.1 Problema

- La información vive en **cuatro formatos sin conexión**: informe anual en PDF (cientos de páginas, a menudo en inglés), gráfico de cotización, audio de la conferencia de resultados y datos de mercado.
- El cruce se hace **a mano**: horas por empresa y sin trazabilidad de cada dato.
- Los asistentes de IA genéricos **inventan cifras**. En finanzas, un número falso es un riesgo regulatorio y reputacional.

1.2 Público objetivo

Segmento	Modelo	Necesidad	Prioridad
Analistas junior y <i>sell-side</i>	B2B	Reducir horas de lectura y de cruce de fuentes	Núcleo
EAFI y asesores independientes	B2B	Respaldar sus informes con fuente citada	Núcleo
Gestoras boutique y relación con inversores	B2B	Notas de research trazables y rápidas	Núcleo
Plataformas de brokers	B2B2C	Embeber el análisis en su producto vía API	Extensión
Inversor minorista	B2C	—	Fuera del MVP: mayor riesgo regulatorio (asesoramiento personalizado)


1.3 Propuesta de valor diferencial

- **Cifras verificadas.** Python comprueba que cada número aparece en la página citada del PDF, en los fundamentales de la SEC o en los indicadores calculados. El LLM no se evalúa a sí mismo.
- **«La IA vio · los datos dicen».** Cada nivel o tendencia que lee el modelo de visión se contrasta con la serie real de precios. Detecta alucinaciones visuales.
- **Cruce entre modalidades.** Informe ↔ gráfico ↔ dirección ↔ mercado. La nota señala coincidencias y contradicciones.

1.4 Multimodalidad: qué aporta cada modelo

Modalidad	Función	Modelo
Texto → texto	Análisis, síntesis y chat con citas	anthropic/claude-sonnet-5.5
Imagen → texto	Lectura del gráfico de velas	google/gemini-3.8-flash
Voz → texto	Transcripción de la conferencia y de la pregunta	openai/whisper-large-v3-turbo
Texto → voz	Resumen hablado con aviso legal	hexgrad/kokoro-82m
Texto → imagen	Ilustración de la infografía (las cifras las dibuja Python)	black-forest-labs/flux.2-klein-4b
Embeddings	Búsqueda multilingüe en el PDF (pregunta en español, informe en inglés)	baai/bge-m3
Datos	Precios, derivados on-chain y fundamentales oficiales	Yahoo Finance · Hyperliquid · SEC EDGAR

El MVP admite **6 entradas** (PDF, gráfico, audio, voz, texto, ticker) y produce **7 salidas** (nota verificada, contraste visión↔datos, audio, infografía, chat, nota en PDF, traza de coste). Ningún modelo único cubre toda la cadena; el valor está en orquestarlos.



Flujo de datos. Las ramas de percepción corren en paralelo; los pasos de control son deterministas.

2. Viabilidad técnica y económica

2.1 Costes de inferencia

Medido con APIs reales sobre el informe anual 2025 de Inditex (gráfico de ITX.MC y audio): **6 ejecuciones, 0 fallos**. El 99 % del coste lo informa el proveedor; el resto se estima con tarifas de respaldo.

LLM · análisis + prompt (claude-sonnet-5.5)	0,0446 USD · 73,8 %
Imagen · flux.2-klein-4b	0,0150 USD · 24,8 %
Texto a voz · kokoro-82m	0,0004 USD · 0,7 %
Embeddings · bge-m3	0,0002 USD · 0,3 %
Voz a texto · whisper-large-v3-turbo	0,0001 USD · 0,2 %

Coste medio por análisis completo (USD) y peso sobre el total de 0,0604 USD.

Componente	Uso medio	Coste (USD)	% del total
LLM · análisis + prompt (claude-sonnet-5.5)	8.849 / 3.092	0,0446	73,8 %
Imagen · flux.2-klein-4b	1 imagen	0,0150	24,8 %
Texto a voz · kokoro-82m	710 caracteres	0,0004	0,7 %
Embeddings · bge-m3	21.395 tokens	0,0002	0,3 %
Voz a texto · whisper-large-v3-turbo	0,7 min	0,0001	0,2 %
Total por análisis		0,0604	100 %

- El **LLM y la imagen** concentran casi todo el coste. Voz, TTS y embeddings suman 1,2 %.
- Omitir la infografía ahorra la imagen y su prompt. Un modelo más barato para el análisis (`gemini-3.8-flash`) baja el coste del LLM.
- Palancas ya implementadas: recuperación híbrida (no se envía el PDF entero), límite de entrada, caché, razonamiento acotado y modelos abiertos baratos.

Análisis al mes	Coste de IA (USD)	+ infraestructura de la demo (12 USD)
100	6,04	18,04
1.000	60,40	72,40
10.000	604,00	616,00


La infraestructura de la demo (1 instancia EC2 t3.micro, IPv4 y disco; ≈12 USD/mes) está dimensionada para pruebas, no para producción.

2.2 Latencias para una experiencia fluida

FinLens no es un chat en tiempo real: sustituye horas de trabajo manual. Proponemos como **objetivo del MVP** la nota en pantalla en **≤ 30 s** y el análisis completo en **≤ 60 s**. La nota se muestra antes que el audio y la infografía (render progresivo).



Latencia media medida frente al objetivo (marca roja). Máximos: nota 24,9 s, total 35,7 s.



Latencia media por paso (s). Dorado: modelo de IA. Gris: paso local. Las ramas paralelas se solapan, por eso los pasos no suman el total.

- El paso más lento es «Análisis (LLM)» (13,9 s).
- Visión, transcripción, embeddings, datos de mercado y SEC corren **en paralelo**. Después corren en paralelo audio e infografía.
- Para bajar la latencia: modelo más rápido en el análisis, *streaming* de la respuesta y caché del índice por documento.


2.3 Marco regulatorio: compliance y privacidad

Marco	Riesgo	Medida en el MVP	Pendiente en producción
MiFID II / CNMV	Pasar de informar a asesorar	Guardrail determinista (ES/EN) que retira la frase de recomendación; aviso legal en cada salida, también hablado	Revisión legal del guardrail (es heurístico)
RGPD	Tratar documentos del usuario	No se almacenan documentos; la caché vive en memoria de la sesión; aviso de envío a proveedores de IA	DPA con los proveedores; residencia de datos en la UE
Datos bancarios (PSD2)	Acceso a cuentas de clientes	Fuera del MVP: no se conecta a cuentas ni pide datos bancarios	Proveedor autorizado (AISP) o socio, consentimiento explícito y revocable, minimización y cifrado
AI Act	Transparencia del contenido generado	Todo se marca como generado por IA; cada afirmación cita su fuente	Evaluación sistemática de precisión
Licencias de datos	Yahoo Finance es una API no oficial	Uso académico	Proveedor con licencia (p. ej. BME Market Data)
Seguridad de la demo	Gasto de crédito por terceros	Contraseña, secretos en Secrets Manager, OIDC entre GitHub y AWS, sin SSH, HTTPS	Autenticación real y multiusuario

2.4 Modelo de monetización

SaaS B2B por volumen de análisis. Coste variable medido: **0,060 USD ≈ 0,055 €** por análisis completo (1 USD ≈ 0,92 €). Los precios son **hipótesis** de la práctica.

Plan	Para quién	Precio	Análisis/mes	Coste IA máx.	Margen bruto
Free	Probar: solo nota, marca de agua	0 €	5	0,28 €	captación
Pro	Analista individual: audio, infografía, chat, mercado	49 €/mes	150	8,25 €	83 % (×2 coste: 66 %)
Team	Gestoras y EAFI (5 usuarios), espacio compartido	390 €/mes	1.000	55,00 €	86 % (×2 coste: 72 %)
API	Brokers (B2B2C): pago por análisis	0,25 €/análisis	por uso	0,055 €	78 % (×2 coste: 56 %)



Reparto del precio entre coste de IA y margen bruto, con el plan usado al máximo de su cupo.

- Margen bruto = (precio – coste de IA) / precio. **No incluye** infraestructura, soporte ni licencias de datos.
- **Sensibilidad:** si el coste de IA se duplicara, el margen bruto bajaría a 66 % (Pro), 72 % (Team), 56 % (API). Seguiría siendo **positivo en todos los planes**.
- El coste de IA de un plan Pro completo (150 análisis) es 8,25 €: el 17 % del precio.

3. Riesgos y límites

Límite	Efecto	Mitigación
Guardrail heurístico	Puede dejar pasar formulaciones muy indirectas	Conservador por diseño; revisión legal antes de producción
La verificación comprueba presencia, no interpretación	Un número correcto puede interpretarse mal	Cita de página; lectura humana de la nota
Sin OCR	Un PDF escaneado no se puede analizar	Error claro al usuario; OCR en la hoja de ruta
Precisión no evaluada de forma sistemática	No hay métrica global de acierto	Conjunto de preguntas con respuesta conocida (siguiente paso)
Dependencia de APIs de terceros	Caída o cambio de precio de un proveedor	Proveedores intercambiables por capacidad; degradación elegante y modo demo
Audios de la demo sintéticos	Los de earnings calls reales tienen derechos de autor	Lectura de extractos del propio informe

4. Estado del MVP y siguientes pasos

- **Estado:** aplicación operativa y desplegada en AWS; más de 800 tests; CI en GitHub Actions (Python 3.11 y 3.12); modo demo sin claves; entradas inválidas con error controlado.
- **Siguientes pasos:** evaluación sistemática de precisión, OCR, *streaming*, proveedor de datos con licencia, multiusuario con autenticación, comparación entre empresas y alertas por ticker.

Fuentes de las cifras: `docs/medidas.md` (medición con APIs reales), `README.md` y `docs/DESPLIEGUE.md`. Tarifas orientativas: verificar en las páginas oficiales de cada proveedor.